

Score matching for the exponential family

Набиев Мухаммадшариф Фуркатович

Московский физико-технический институт

9 ноября 2023 г.

¹Пусть имеем статистическую модель, которая задана плотностью из экспоненциального семейства распределений

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{Z(\boldsymbol{\theta})} e^{\boldsymbol{\theta}^T \mathbf{F}(\mathbf{x})}, \quad (1)$$

где $Z(\boldsymbol{\theta})$ — нормализационная константа и $\mathbf{F}(\mathbf{x})$ — достаточная статистика.

Всюду далее будем рассматривать натуральный логарифм от плотности

$$\ln p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{k=1}^K \theta_k F_k(\mathbf{x}) - \log Z(\boldsymbol{\theta}) \quad (2)$$

¹Michael U. Gutman - Exercises in Machine Learning

Нашей задачей является найти минимум следующей функции

$$J(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \left[\partial_j \psi_j(\mathbf{x}_i; \boldsymbol{\theta}) + \frac{1}{2} \psi_j(\mathbf{x}_i; \boldsymbol{\theta})^2 \right], \quad (3)$$

где $\psi_j(\mathbf{x}; \boldsymbol{\theta}) = \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial x_j}$ и $\partial_j \psi_j(\mathbf{x}; \boldsymbol{\theta}) = \frac{\partial^2 \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial x_j^2}$

Посчитаем производные

$$\psi_j(\mathbf{x}; \boldsymbol{\theta}) = \frac{\partial \ln p(\mathbf{x}; \boldsymbol{\theta})}{\partial x_j} = \sum_{k=1}^K \theta_k \frac{\partial F_k(\mathbf{x})}{\partial x_j} = \sum_{k=1}^K \theta_k K_{kj}(\mathbf{x}),$$

$$\partial_j \psi_j(\mathbf{x}; \boldsymbol{\theta}) = \sum_{k=1}^K \theta_k \frac{\partial^2 F_k(\mathbf{x})}{\partial x_j^2} = \sum_{k=1}^K \theta_k H_{kj}(\mathbf{x}),$$

где $K_{kj}(\mathbf{x}) = \frac{\partial F_k(\mathbf{x})}{\partial x_j}$ и $H_{kj}(\mathbf{x}) = \frac{\partial^2 F_k(\mathbf{x})}{\partial x_j^2}$. По этим элементам построим матрицы $\mathbf{K}(\mathbf{x})$ и $\mathbf{H}(\mathbf{x})$.

Возведем в квадрат $\psi_j(\mathbf{x}; \boldsymbol{\theta})$

$$\psi_j(\mathbf{x}; \boldsymbol{\theta})^2 = \left[\sum_{k=1}^K \theta_k K_{kj}(\mathbf{x}) \right]^2 = \sum_{k_1=1}^K \sum_{k_2=1}^K K_{k_1 j}(\mathbf{x}) K_{k_2 j}(\mathbf{x}) \theta_{k_1} \theta_{k_2} \quad (4)$$

Тогда

$$\begin{aligned} \sum_{j=1}^m \psi_j(\mathbf{x}; \boldsymbol{\theta})^2 &= \sum_{j=1}^m \sum_{k_1=1}^K \sum_{k_2=1}^K K_{k_1 j}(\mathbf{x}) K_{k_2 j}(\mathbf{x}) \theta_{k_1} \theta_{k_2} = \\ &= \sum_{k_1=1}^K \sum_{k_2=1}^K \sum_{j=1}^m K_{k_1 j}(\mathbf{x}) K_{k_2 j}(\mathbf{x}) \theta_{k_1} \theta_{k_2} = \\ &= \boldsymbol{\theta}^T \mathbf{K}(\mathbf{x}) \mathbf{K}(\mathbf{x})^T \boldsymbol{\theta} \quad (5) \end{aligned}$$

Подставим

$$\begin{aligned}
 J(\theta) &= \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \left[\sum_{k=1}^K \theta_k H_{kj}(\mathbf{x}) + \frac{1}{2} \sum_{k_1=1}^K \sum_{k_2=1}^K K_{k_1 j}(\mathbf{x}) K_{k_2 j}(\mathbf{x}) \theta_{k_1} \theta_{k_2} \right] = \\
 &= \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \theta^T \mathbf{h}_j(\mathbf{x}) + \frac{1}{2n} \sum_{i=1}^n \sum_{k_1=1}^K \sum_{k_2=1}^K \sum_{j=1}^m K_{k_1 j}(\mathbf{x}) K_{k_2 j}(\mathbf{x}) \theta_{k_1} \theta_{k_2} = \\
 &= \theta^T \left[\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \mathbf{h}_j(\mathbf{x}_i) \right] + \frac{1}{2} \theta^T \left[\frac{1}{n} \sum_{i=1}^n \mathbf{K}(\mathbf{x}_i) \mathbf{K}(\mathbf{x}_i)^T \right] \theta \quad (6)
 \end{aligned}$$

Обозначив

$$\mathbf{r} = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^m \mathbf{h}_j(\mathbf{x}_i) \quad \mathbf{M} = \frac{1}{n} \sum_{i=1}^n \mathbf{K}(\mathbf{x}_i) \mathbf{K}(\mathbf{x}_i)^T \quad (7)$$

Получим квадратичную форму следующего вида

$$J(\boldsymbol{\theta}) = \frac{1}{2} \boldsymbol{\theta}^T \mathbf{M} \boldsymbol{\theta} + \boldsymbol{\theta}^T \mathbf{r} \quad \square \quad (8)$$

- Представив $J(\theta)$ как квадратичную форму, мы можем аналитически найти минимум из уравнения $\nabla J(\theta^*) = 0$.
- Для нормальных распределений со средним равным 0, оценка θ^* полученная нашим методом, совпадает с оценкой по методу максимального правдоподобия.